

Phi-tiny-MoE-instruct Prefill 병렬화 최적화 보고서

RTX 3090 1장 · CUDA · n=1024 (19,803 토큰 / trie 15,583 노드) · 측정 대상은 generate() 구간 · 실험 기록 docs/lab-note.md

제출자 **aps17 송영재** · **aps20 신정수**

최종 처리량 (b/s) 687.8 seq/s 3rep 최고 687.79(제출) · b7 604.0	baseline 대비 20,651× 0.0333 → 687.8 seq/s	검증 (임계 3e-3) 1.79e-4 max abs diff · PASSED	실험 65 건 채택 39 · 기각 25 + 측정 12
---	---	---	--

방법론. 실험 1건 = 가설 1개 = 커밋 1개. 노드별 SM 클럭이 부하 중 **1395~1770 MHz**로 갈려 같은 바이너리의 처리량이 $\pm 12\%$ 움직인다(§ 1) — 그래서 모든 A/B는 **같은 srun allocation 안에서 교차 실행했다**. **판정 기준은 출력 131 MB의 bitwise 동일(cmp)**이다 — EXP-004에서 layer_norm을 tree reduction으로 쓰자 router logit이 1e-7 흔들려 **top-2 expert 집합이 뒤집히고** 1024개 중 4개 시퀀스가 검증 실패했다. EXP-051이 재확인했다(합산 순서만 역순으로 바꿔 max diff 1.79e-4 → 1.91e-2, FAILED). 따라서 누산 순서 보존은 조심이 아니라 **필수 조건**이고, 이 제약이 이후 모든 설계를 결정한다. 표의 **누적 seq/s**는 그 실험까지 반영한 처리량으로, § 5 궤적과 같은 정규화 값이다(EXP-001·002는 n=8, 003 이후 n=1024).

1. 성능 평가 결과 — 자체 측정. git HEAD 9970b05 (EXP-065) · ./main -n 1024 · 노드당 한 allocation 안에서 3rep · 워밍업 없음

노드	rep1 (s)	rep2 (s)	rep3 (s)	평균 elapsed	평균 throughput	vs 최고
b5	1.4975	1.4888	1.4915	1.4926 s	686.06 seq/s	—
b6	1.5011	1.4975	1.5020	1.5002 s	682.56 seq/s	-0.5%
b0	1.5134	1.5083	1.5071	1.5096 s	678.32 seq/s	-1.1%
b1	1.5082	1.5108	1.5107	1.5099 s	678.19 seq/s	-1.1%
b7	1.6972	1.6942	1.6951	1.6955 s	603.96 seq/s	-12.0%

검증: 위 전 런이 -v 동봉이며 모두 **PASSED** · max abs diff **1.79e-4** · mean abs diff 1.27e-5 (임계 3e-3의 6%) — 전 런 동일값. 모델 로드 ~6s는 측정 구간 외. rep 내 편차는 최대 **0.58%**이고 **노드 간 격차 -12.0%**는 코드가 아니라 GPU 클럭이다 — EXP-055 시점의 클럭 스릴에서 b7만 부하 중 1395 MHz / 217 W에 고정되고 나머지 4개는 1605~1770 MHz / ~300 W로 전력 상한 근처였다. 그래서 단일 대표값 대신 파티션 5개 노드를 전부 싣는다. 원본 로그: outputs/perf-eval-065/ · 클럭 샘플: outputs/perf-eval-055/.

2. 구조상의 최적화 — 연산을 어디서, 몇 번 하는가

EXP	근거 (실측)	기법	Before → After	Speedup	누적 seq/s
001	모든 GEMM이 $M \approx 19$ 행, 총 가중치 470 MB를 시퀀스마다 재스트리밍	전 시퀀스를 [T, 4096] 단일 활성 행렬로 배치화 + attention q·k 내적 130회 재계산 제거	시퀀스별 forward 1024회 → 19,803행이 32층을 1회 통과	2.88×	0.13
002	Tensor::at() 경유 matmul이 shape 무관 1.2 GMAC/s = CPU 피크의 1%	q/k/v/o·lm_head를 자체 shared-tiled CUDA GEMM으로, 가중치 2.7 GB device 상주	연산량의 66%를 host → device	1.69×	0.22
003	프로파일: MoE가 98.1% (28.0 s / 28.6 s). GPU로 옮긴 projection은 0.15 s	MoE 전체를 커널화(gather → expert GEMM → silu·mul → scatter), expert 가중치 11.3 GB 상주	n=1024 전량이 2분 제한 안으로 진입	35.9×	21.0
004	host norm/resid/attn 20.1 s + 그 때문에 발생하는 PCIe 왕복 10.1 s = 53%	layer_norm·residual add 커널화, residual stream을 32층 내내 device 상주(double buffer)	층당 버스 왕복 → router logit 1건만 남김. d2h 7.5 → 0.85 s	2.02×	42.5
006	attention 관련이 2.54 s = 40% (host 1.13 + q/k/v·context 버스 왕복 1.38)	RoPE + softmax attention 커널화. cos/sin 표만 host 계산 후 업로드(device trig는 1 ulp 차이로 라우팅을 뒤집음)	d2h 0.865 → 0.006 s (144×), 활성값이 device를 떠나지 않음	1.61×	260
011	causal + 절대위치 RoPE → 앞 토큰이 같은 두 토큰은 32층 전부에서 동일 hidden state	행 단위를 토큰 → prefix trie 노드 로 (순수 CSE, 산술 변경 0)	19,803 → 15,583 노드 (-21.3%). 행에 비례하는 전 항목 감소	1.24×	372
012	nsys: expert w13의 시간가중 wave 총전율 66%, 시간의 53%가 1 wave(164블록) 미만 launch	16개 expert의 행을 한 버퍼에 패킹하고 (expert, rowtile) work queue로 평탄화	launch 16 → 1, 총전율 49% → 85%	1.07×	397
013	embedding gather가 host 단일 스레드로 255 MB 수집 + 255 MB 업로드	embedding table 525 MB를 다른 가중치와 같이 로드 시점에 device로, gather_rows 재사용	0.180 → 0.002 s	1.10×	437
015	MoE 라우팅이 총마다 host를 왕복: score D2H + host top-2/타일 빌드 = 0.060 s (2.6%)	device counting-sort 3-pass 라우팅(count → scan → place)으로 host와 동일한 packed 레이아웃 재현	host 라우팅 삭제 + 층당 255 MB cudaMemset(총 8.2 GB) 삭제	1.03×	465
040	입력이 짧아(평균 19.3 토큰) lm_head가 실제로 읽는 행은 15,583 중 1,024 (6.6%)	마지막 층의 q_proj·rope·attn_o_proj·norm·MoE만 1024행 경로로, k/v는 조상 키가 필요해 전 행 유지	마지막 층 58.2 → 13.4 ms . 건너편 행은 아무도 안 읽으므로 비트 동일	1.025×	638

3. 그 외 최적화 — 커널 밖: host 작업 · 할당 수명 · 전송


EXP	근거 (실측)	기법	Before → After	Speedup	누적 seq/s
014	logits 131 MB의 Tensor 할당+제로필이 69 ms 이고 그 제로는 직후 D2H가 덮어쓰. GPU 무의존 host 작업	진입부에서 별도 스레드로 할당을 시작하고 D2H 직전에 join (JoinGuard RAI)	0.069 → 0.000 s , 다른 구간 퇴행 0	1.030×	450
021	측정-E: 에필로그 cudaFree 24회(~1.5 GB)가 구간 안에서 20.77 ms , 그 동안 GPU idle	스크래치 24개를 모델 메모리로 올려 grow-only reserve()로 재사용, 해제는 모델 소멸자로 유지)	해제만 구간 밖으로 (cudaMalloc은 구간 안에 유지)	1.011×	542
033	D2H가 pageable 7.6 대 pinned 25.9 GB/s. 단 구간 안 page-lock은 어느 스레드에 올려도 안 쓴다 (030 실측 +105 ms — 컨텍스트 락이 launch를 막음)	Tensor에 pinned 할당자를 추가하고 생성자에서 256 MB 예산을 예약해 std::move로 넘김	D2H 15.0 → 5.0 ms . 페이지 락 220 ms는 구간 밖(생성자)	1.005×	587
031 032	attention의 dynamic shared가 키 수에 선형 (516+136·nk B)인데 블록 한도 48 KB에 걸림. 인덱스 버퍼는 total < batch/2에서 오버런	shared 산정을 sliding window 기준으로, 48 KB 초과 시에만 cudaFuncSetAttribute opt-in	입력 길이 절벽 357 → 741 토큰	방어	—

4. 커널 상의 최적화 — 커널 내부: 타일 · shared 경로 · 융합. 전부 ncu/nsys 실측이 먼저이고 가설은 그 지표 하나를 겨눈다. 융합 기준(EXP-024): 루프라인(DRAM 90%+) 엘리먼트와이즈 커널은 빠르게 만들 수 없고 삭제만이 길이며, 계산 바운드 생산자의 유휴 DRAM에 접는다

EXP	근거 (실측)	기법	Before → After	Speedup	누적 seq/s
005	thread당 출력 1개 → MAC마다 shared 2회 읽기. 실효 2.0 TFLOP/s = 피크의 6%	레지스터 타일 4×4 (64×64, BK=16). shared를 k-major 전치 저장 + float4 로드, +4 패딩으로 16 B 정렬 유지	shared 읽기/MAC 2 → 0.5. 피크 6% → 44%	3.77×	161
010	ncu: expert N=448에 BN=128이면 12.5% 폐기 , 블록도 80개(상주 164 슬롯의 49%)	w1 w3를 행방향으로 쌓아 N=896=7×128 한 장으로 융합 (launch 2 → 1)	패딩 0, 충전을 49% → 85% . 예측의 3배	1.08×	300
017	ncu: bs 읽기가 명령당 wavefront 5.0 · conflict 2.0 . 패딩으로는 불가(베이스가 회전만 함)	레이나가 갖는 8열을 4열씩 반 타일 떨어뜨려 quarter의 8레이니 32뱅크를 한 번씩 덮게 (gemm_col_slot)	conflict 2.0 → 0 , wavefront 5.0 → 3.0. 단일 실험 최대 레버	1.09×	516
019	ncu: FMA 59% · l1tex 63%로 둘 다 미포화 , long_scoreboard 0.92 = 지연 바운드. 타일 형상 측은 산술로 닫힘	남은 측인 BK를 8 → 16 (2블록/SM 유지 최대폭) + __launch_bounds__ 점유율 고정	long_sb 0.92 → 0.02 , FMA 59 → 67%	1.04×	536
023	ncu: layer_norm_rows barrier stall 16.67 — 256스레드 중 1스레드만 일할. 행당 shared 16 KB 라 동시 체인 5개/SM	1행 = 1레이니(32행 = 1워프). 열을 청크로 shared에 전치 스테이징, 로드는 레지스터로 배치 후 STS	barrier 0 , DRAM 34% → 89% (루프라인 도달)	1.015×	550
024	add_inplace 905 μs/층, DRAM 92.7% = 루프 라인. 빠르게 만들 길이 없다	residual add를 각자의 생산자 에필로그 (o_proj GEMM / w2 combine)로 융합	3유닛 → 1유닛, 그 1유닛도 o_proj의 유휴 DRAM(4%)에 숨음 → 실효 +0.002 s	1.025×	564
025	moe_combine 1.18 ms/층, 1.02 GB, DRAM 95.1%	w2 에필로그로 융합. atomic은 그루핑을 깨므로 (expert, 순번) 32 서브레이니 로 패킹해 launch 2개로 순서를 확보	511 MB expert-output 버퍼 왕복 삭제. 상한 37.8 중 26 ms 회수	1.011×	570
026	ncu: shared store wavefront 32(이상값 16) = 절반이 conflict. 패딩으로는 불가 — stride=2 (mod 8) 와 float4의 ≡0 (mod 4)가 양립 불가	시프트를 stride가 아니라 열 에 넣어 k그룹 4개가 서로 다른 뱅크 옥텟을 잡게 (SPAD 4 → 32)	store conflict → 0 , SASS 명령 수 불변 (2552 → 2552)	1.015×	579
034	ncu: occupancy 98.1% · Mem Pipes Busy 77.5% → 점유율이 아니라 명령 수가 벽. QH/KVH=4라 q head 4개가 같은 k·v를 4번 읽음	GQA group 1개를 1블록으로 (grid 16 → 4). v를 1번 읽어 레지스터에서 4 head가 재사용. nk≤32에서 1 워프만 일하던 것도 해소	global load -74% , 커널 3.34 → 1.37 ms, SM 77.5 → 86.9%	1.033×	606
037	측정-J: norm 3패스는 상주로 못 줄인다(레지스터 32배 부족). 남은 레버는 바이트뿐 — x를 3번 읽어 766 MB read	3번째 패스(apply)를 소비자로 이관. gate는 컬럼 타일 1개, expert gather는 DRAM 바운드로 둘 다 ALU 가 공짜	쿨당 1.019 → 0.511 GB . 소비자 비용 실측 +2 μs	1.009×	615
038	gather_rows(expert)가 층당 1.22 ms · 총 39 ms의 순수 복사 (511 MB 읽고 511 MB 쓰기)	w13 GEMM이 어차피 PA를 행 단위로 스테이징하므로 그 행 주소를 arowmap[r]로 간접화 — 커널 자체가 사라진다	커널 삭제(층당 1.02 GB 제거). 대가는 A 스테이징 7회 반복	1.013×	623
055	ncu: w13의 store conflict가 63.2 M = o_proj의 23배. 049는 "039가 이미 기각"으로 적었지만 039가 측정된 것은 w2 인스턴스였다	026의 store swizzle를 gemm_grouped(w13) 인스턴스에만 켜 (2층). w2는 039의 기각을 존중해 유지	conflict 64.7 → 5.4 M , 13.86 → 13.61 ms. 레지스터 128 → 127	1.004×	644

표에 올리지 않은 채택 건: **008** shared 더버 버퍼 + 8×8 타일 — 실제로 작동한 것은 지연 은닉이 아니라 반복당 BAR.SYNC 2 → 1(15.5 → 19.9 TF/s, 1.04×) · **028** gate가 out=16인데 타일이 BN=128이라 112열(87.5%)을 버리므로 tall-skinny 전용 커널로(1.11 → 0.60 ms/층, 1.008×) · **009** softmax의 double exp를 128 lane에 분산(attn 1.59×) · **016** attention key를 32열 청크로 shared 스테이징 · **035·036** 나눗셈 호이스팅과 shared float4 로드(-62%) · **042** w13 가중치 행 인터리브로 silu를 에필로그로 · **046** norm 에필로그 독립 런치. **EXP-056~065**(채택 4 · 기각 6, 누적 644 → 673): **060** FFMA 발사 순서를 j-외/i-내로 — 레지스터 뱅크 충돌 53% → 17%(+2.28%, 이 구간 최대) · **063** shared 스토어를 p 루프 중간으로 (+1.23%) · **062** 레이어 0의 투영을 distinct 토큰으로(+0.81%) · **065** logits D2H를 lm_head GEMM 뒤로 숨김(+0.11~0.35%).

5. 처리량 궤적 — x: 실험 인덱스, y: seq/s (log). 기각 실험은 코드를 원복했으므로 값이 유지된다



각 실험의 같은-allocation A/B 비를 이어 붙여 빠른 **노드 기준으로 정규화**했다(체인 최종 673.2에 §1의 b5 실측 687.8 — 2.2% 차, 노드 클럭). EXP-000~002는 n=1/n=8, 003 이후는 n=1024. 로 그측에서 후반이 평평하므로 EXP-016 이후를 선형 확대했다. 리더보드 제출값은 b5 실측 **687.793880 seq/s**다.

6. 기각 25건의 사유 — 네 가지로 수렴한다

도달한 천장은 **GEMM의 FMA 피크 70%**(= FFMA 명령비 89.5% × 발사율 78.5%, 측정-K)이고 그 두 항 모두 **128 레지스터 × 512 스레드 = 레지스터 파일 100%**에 막혀 있다. 대역폭 커널은 DRAM 88~93.5%로 이미 루프라인이다. 그래서 남은 시도는 전부 다음 네 형태로 실패했다. ① **병목이 아닌 자원을 비운다** — DRAM이 12~38%인 커널에서 트래픽·FLOP을 지워도 0 또는 손해(047, 053, 057, 061). ② **명령 수를 줄인다** — ptxas가 이미 숨기고 있어 live range 대가가 더 크다(049, 054, 059, 064). ③ **타일 모양을 바꾼다** — 포화한 파이프를 다른 포화한 파이프와 교환한다(022b, 050, 052, 056, 058). ④ **reduction을 재배치한다** — 라우터 top-2가 1e-7 섭동에 뒤집혀 검증 실패(051). 텐서코어는 044가 닫았다: GA102는 **TF32가 FP32 FFMA와 동등 (38 TFLOP/s)**이라 이득이 FP16에만 있는데, 전 GEMM FP16 프로브가 max abs **4.34**(임계의 1448배)로 기각됐고 규칙상 양자화도 금지다.